

Universidade Federal de Minas Gerais
Instituto de Ciências Exatas
Departamento de Ciência da Computação

PEDRO HENRIQUE RAMOS COSTA

MONOGRAFIA DE PROJETO ORIENTADO EM COMPUTAÇÃO I
ANÁLISE DE SENTIMENTO EM NOTÍCIAS NACIONAIS

Belo Horizonte
Dezembro de 2015

Universidade Federal de Minas Gerais
Instituto de Ciências Exatas
Departamento de Ciência da Computação
Curso de Bacharelado em Ciência da Computação

ANÁLISE DE SENTIMENTO EM NOTÍCIAS NACIONAIS

por

PEDRO HENRIQUE RAMOS COSTA

Apresentado como requisito na disciplina de Projeto Orientado em Computação do Curso
de Bacharelado em Ciência da Computação da UFMG

Prof. Dr Fabrício Benevenuto
Orientador
Dr. Julio Reis
Co-orientador

Belo Horizonte
Dezembro de 2015

"Não há caminho para a paz. A paz é o caminho."

Mahatma Gandhi

RESUMO

Uma das tarefas mais básicas em análise de sentimentos é a mineração de opinião ou análise de polaridade, em que extrai-se a polaridade de um texto (negativo, neutro ou positivo). Neste trabalho, aplicou-se métodos de análise de sentimentos sobre manchetes de notícias brasileiras colhidas de 8 grandes jornais por um período de 3 meses. Utilizou-se a ferramenta de análise combinada de métodos, o iFeel, que combina 12 métodos diferentes, e que está disponível para análises sobre textos em inglês. Para evitar perda de informação na tradução, optou-se por executar um método na língua nativa. O método SentiStrength é baseado em aprendizado de máquina sobre textos de redes sociais, e está disponível em português. Ele define, para o texto, um valor de sentimento de -4 a 4. A execução do SentiStrength sobre os dados coletados provou que o método é conciso e eficaz. Analisou-se a quantidade relativa de notícias de cada polaridade, a polaridade média das notícias no tempo decorrido e por jornal, e a distribuição de notícias entre os scores retornados pelo SentiStrength. Extraíu-se entidades das manchetes para momentos de polaridade muito positiva e muito negativa para demonstrar a eficácia do método.

Palavras-chave: análise de sentimento; mineração de opinião; manchetes; polaridade; sentistrength; ifeel

ABSTRACT

One of the simplest tasks in sentiment analysis is opinion mining - to determine the polarity of a text (negative, neutral or positive). In this work, several sentiment analysis methods were executed on news headlines that were collected from eight major national journals for 3 months. iFeel, a tool that combines 12 different sentiment analysis methods, and is only available for analysis in English, was utilized on some of the dataset. In order to avoid information loss due to translation, a method capable of running on native language (Portuguese) was chosen. The SentiStrength method is based on machine learning concepts upon social web texts such as tweets, and is available for analysing texts in Portuguese. It returns a value between -4 and 4 for the input text or sentence. Its execution upon the collected data has proven that the method is precise and efficient. Part of the carried out analysis regarded the relative amount of news for each polarity level, the average polarity along time and the distribution of the news between the given scores. The entities associated to moments of extreme positivism and extreme negativism on news were extracted, in an attempt to evidence the method's effectiveness.

Keywords: sentiment analysis; opinion mining; polarity; headlines; news; sentistrength; ifeel

ÍNDICE DE FIGURAS

FIGURA 1: FLUXO METODOLÓGICO	17
FIGURA 2: QUANTIDADE DE NOTÍCIAS COLETADAS NO PERÍODO	18
FIGURA 3: EXEMPLOS DE MANCHETES AVALIADAS PELO SENTISTRENGTH	20
FIGURA 4: QUANTIDADE RELATIVA DE NOTÍCIAS POSITIVAS, NEUTRAS E NEGATIVAS	21
FIGURA 5: NOTÍCIAS ANALISADAS POR JORNAL	21
FIGURA 6: NOTÍCIAS POR SCORE (AGREGADO)	22
FIGURA 7: NOTÍCIAS POR SCORE (POR JORNAL)	22
FIGURA 8: QUANTIDADE POR SCORE (AGREGADO)	23
FIGURA 9: MÉDIA POR DIA DA SEMANA	23
FIGURA 10: MÉDIA DE SCORE AO LONGO DO TEMPO (AGREGADO)	24
FIGURA 11: ENTIDADES (GERAL)	25
FIGURA 12: ENTIDADES (13-16 NOVEMBRO)	25
FIGURA 13: ENTIDADES (22 NOVEMBRO)	25
FIGURA 14: JORNAIS AO LONGO DO TEMPO	26

ÍNDICE DE TABELAS

TABELA 1: QUANTIDADE DE NOTÍCIAS COLETADAS NO PERÍODO	18
---	----

LISTA DE SIGLAS

ANJ: Associação Nacional de Jornais

DCC: Departamento de Ciência da Computação

SVM: Support Vector Machine

UFMG: Universidade Federal de Minas Gerais

SUMÁRIO

RESUMO	4
ABSTRACT	5
ÍNDICE DE FIGURAS	6
ÍNDICE DE TABELAS	7
LISTA DE SIGLAS	8
1. INTRODUÇÃO	10
2. OBJETIVO	12
3. FUNDAMENTAÇÃO TEÓRICA	13
4. TRABALHOS RELACIONADOS	15
5. DESENVOLVIMENTO	17
6. RESULTADOS	20
7. CONCLUSÃO E TRABALHOS FUTUROS	27
8. REFERÊNCIAS	28

1. INTRODUÇÃO

Identificar automaticamente opiniões ou tendências em um texto tem sido um foco de atenção nos últimos anos em diferentes domínios como notícias, blogs, artigos e *reviews* de usuários. Várias técnicas de abordagem são utilizadas para detectar subjetividade em um texto. O campo de estudos nesse sentido é mais conhecido como "análise de sentimentos" (também conhecido como "mineração de opinião"). Análise de sentimento refere-se, portanto, ao uso de processamento de linguagem natural e linguística computacional para identificar e extrair informações subjetivas (ou seja, do escritor) em um texto.

De forma geral, as técnicas de análise de sentimentos tem como objetivo determinar o sentimento do interlocutor ou do escritor no tocante a algum tópico, ou determinar a polaridade contextual geral de um documento. O sentimento pode ser um julgamento moral ou avaliação sobre determinado assunto, um estado afetivo (isso significa, o estado emocional do autor ao escrever), ou a intenção que o autor deseja causar no leitor.

Uma das tarefas mais básicas em análise de sentimentos é determinar a polaridade de um determinado texto. Isso significa determinar se uma opinião expressa naquele texto é positiva, negativa ou neutra. De forma mais avançada, a análise de sentimentos observa, por exemplo, estados emocionais além da polaridade, como "raiva", "tristeza" e "felicidade".

Neste trabalho, foram aplicados métodos de análises de sentimentos sobre manchetes de notícias nacionais com o objetivo de determinar a polaridade das notícias.

Trabalhos de análise de polaridade sobre manchetes já foram feitos anteriormente com notícias em inglês, [2, 3] porém nenhum trabalho parecido foi realizado sobre um conjunto de dados em português. Uma das motivações para a realização do trabalho é, então, realizar uma análise em um contexto nacional.

Além disso, acredita-se que as manchetes afetam a forma como o leitor recebe a notícia. [1] Portanto é justificável que a análise seja feita somente

sobre as manchetes, para determinar o sentimento inicial do leitor ao se deparar com uma notícia.

2. OBJETIVO

O objetivo principal deste trabalho é determinar se os principais jornais brasileiros reportam mais notícias positivas ou negativas de acordo com as métricas e métodos de análise de polaridade.

Um outro objetivo secundário mas não menos importante é determinar se há alguma mudança na polaridade das notícias ao longo do tempo, e se há alguma relação entre o tempo e a quantidade de notícias positivas ou negativas.

Também foi realizada uma extração de entidades das notícias para tentar determinar quais entidades são noticiadas com notícias mais positivas, e quais estão associadas a notícias mais negativas.

3. FUNDAMENTAÇÃO TEÓRICA

Mineração de opinião, conhecida como Análise de Sentimento, é a extração de opiniões positivas ou negativas de um texto não estruturado [4]. As múltiplas aplicações desta técnica incluem detectar a popularidade de um filme através de *reviews*, detectar quais produtos agradam o público em uma loja online através de comentários e etc.

Tipicamente a mineração de opinião ocorre em 2 ou 3 estágios, embora mais estágios possam ser necessários para algumas tarefas [5]. O texto é inicialmente dividido em frases, e cada frase é analisada quanto a sua subjetividade ou objetividade [4]. As frases consideradas muito subjetivas são analisadas quanto a sua polaridade e o sentimento pode então ser extraído. Mineração de opinião se relaciona, geralmente, com negatividade e positividade, e não com sentimentos complexos (felicidade, surpresa, medo, etc). Também não determina a força do sentimento (o quão negativo e o quão positivo é o texto), tampouco determina ao mesmo tempo sentimentos opostos (negativo e positivo). [6]

Algoritmos de mineração de opinião geralmente utilizam aprendizado de máquina para identificar características globais associadas à positividade ou à negatividade de um texto. Essas características podem ser um subconjunto de palavras de um documento, ou partes de um discurso (frases ou expressões conhecidas). [7]

Em termos de algoritmos de classificação, SVM's (support vector machines) são amplamente utilizados em extração de sentimentos [8] pois eles parecem ter uma performance tão boa quanto ou até melhor que outros métodos num contexto de aprendizado de máquina.

Outras abordagens foram utilizadas para detectar o sentimento em um texto. Uma delas é o uso de um dicionário de palavras positivas e negativas como o encontrado em SentiStrength [6] e outros métodos de análise de sentimentos como General Inquirer, WordNet Affect, SentiWordNet e Q-WordNet. [9,10,11, 12]

Uma alternativa é o uso regras linguísticas simples baseadas em semântica (informação a respeito da probabilidade de significado de uma palavra baseado no texto ao redor da mesma) para detectar a polaridade de

uma expressão. [13] Esta técnica provém bons resultados em frases contidas em textos já conhecidamente com níveis médios de sentimento positivo e negativo. Essa abordagem é mais propícia para casos em que há um grande volume de texto gramaticalmente correto, a partir do qual regras podem ser extraídas.

Características linguísticas também tem sido utilizadas com sucesso para ampliar a mineração de opinião de tal forma que seja capaz de determinar opiniões sobre diferentes aspectos de um mesmo assunto. [14]

4. TRABALHOS RELACIONADOS

Em 2013, uma análise de polaridade sobre manchetes em inglês foi realizada sobre 7 fontes diferentes [2] utilizando a AlchemyAPI. [15] Neste trabalho, notícias de 2008 a 2013 foram coletadas através do arquivo de Internet WaybackMachine [16]. Uma ferramenta de visualização da polaridade média das notícias ao longo dos anos foi implementada.

Em 2015, um trabalho mais completo foi realizado sobre notícias em inglês. [3] Coletou-se notícias de 4 jornais, juntamente com seus comentários. Analisou-se não somente a polaridade das notícias mas também sua força, ou seja, o quão negativa e o quão positiva a manchete era baseado num fator escalar de -5 a 5. Além disso inferiu-se a popularidade das notícias através de comentários e de redirecionamento de links em tweets, e mostrou-se uma correlação entre popularidade e negatividade das notícias (notícias mais negativas foram mais populares). Analisou-se a evolução do sentimento das notícias no decorrer do tempo e em relação à categorias das notícias. Mostrou-se que notícias categorizadas como 'Mundo' foram as mais negativas. [3]

iFeel

iFeel é uma ferramenta web idealizada e implementada no Departamento de Ciência da Computação da UFMG. iFeel confere acesso à doze métodos de análise de sentimento existentes: SentiWordNet, Emoticons, PANAS-t, SASA, Happines Index, Sentic-Net, SentiStrength, EmoLex, NRC Hashtag, OpinionLexicon, Sentiment140 Lexicon, Stanford Recursive Deep Model, Vader e outros. Com o iFeel, usuários podem combinar estes métodos e criar um novo método combinado que alcança maior cobertura. iFeel também provê uma plataforma única para comparar as vantagens e desvantagens de cada um dos métodos de análise de sentimento com uma interface simples e prática (através de upload de arquivos), além de exibir análises gráficas. [17]

SentiStrength

O SentiStrength é um método de análise de sentimento desenvolvido na Universidade de Wolverhampton, no Reino Unido. Por razões a serem explicadas na próxima sessão, o método escolhido para este trabalho foi o SentiStrength. O SentiStrength está disponível em várias linguagens, inclusive na língua Portuguesa. [19]

O SentiStrength estima a força do sentimento positivo e do sentimento negativo em textos curtos, mesmo em linguagem informal. Tem uma acurácia boa para textos curtos extraídos de redes sociais em Inglês, exceto textos políticos. SentiStrength retorna dois valores: -1 (negativo) a -5 (extremamente negativo) e 1 (positivo) a 5 (extremamente positivo). Há outras formas de output, como a binária (positivo ou negativo), trinária (positivo, negativo ou neutro) e escalar (-4 a 4). Foi originalmente desenvolvido para o Inglês e otimizado para textos de redes sociais genéricos, mas pode ser configurado para outras linguagens e outros contextos mudando-se os arquivos de base.

5. DESENVOLVIMENTO

Metodologia

O trabalho foi dividido em 2 fases. Cada fase foi subdividida em tarefas e um fluxo metodológico foi construído (figura 1)




Figura 1: Fluxo metodológico

Fase 1: Coleta

Foram coletadas notícias de 8 jornais diferentes. Para determinar as fontes de coleta, analisou-se a lista dos maiores jornais em circulação impressa e digital na ANJ (Associação Nacional de Jornais) [20]. Além disso, avaliou-se a disponibilidade de cada jornal para coleta de notícias via Feed RSS, para maior praticidade na coleta. Determinou-se 8 jornais: G1 (O Globo), R7, Yahoo Notícias, UOL, A Tarde, O Tempo, Estado de Minas e Folha de São Paulo.

O algoritmo para coleta dos dados foi implementado em Python 2.7, e o banco de dados utilizado para armazenar os dados foi o MySQL. A coleta foi realizada entre os dias 06 de Setembro de 2015 e 30 de Novembro de

2015, um período de 86 dias. Na Tabela 1 vemos as quantidades de notícias coletadas por jornais neste mesmo período.

Jornal	Total coletado	Média de notícias/dia (~)
A Tarde	658	8
Estado de Minas	8687	101
Folha	7228	84
G1	13664	159
O Tempo	3984	46
R7	8325	97
UOL	7707	90
Yahoo	9257	108
AGREGADO	59510	692

Tabela 1: Quantidade de notícias coletada no período

Na figura 2 também observamos que há uma disparidade entre a quantidade absoluta de notícias coletadas de fontes como o G1 e fontes como o jornal A Tarde. Dessa forma, determinou-se que as análises não poderiam ser feitas sobre os números absolutos, e sim sobre as quantidades relativas.




Figura 2: Quantidade de notícias coletadas no período

Fase 2: Análise de sentimento

Para determinar o melhor método de análise de sentimento, foi feita uma seleção aleatória de 100 notícias do dataset coletado, com um mesmo número de notícias por fonte (aproximadamente 12 notícias por fonte). 3 pessoas diferentes etiquetaram as notícias como Negativa, Neutra ou Positiva. O valor mais comum entre as três etiquetas diferentes predomina. Caso há três valores diferentes, a notícia é caracterizada como neutra.

Submeteu-se o dataset de 100 notícias etiquetadas ao iFeel e estudou-se quais os métodos proveram maior acurácia. Para submeter ao iFeel foi preciso traduzir as notícias para o inglês. Utilizou-se a API do Microsoft Translator [21].

Os resultados do iFeel demonstraram uma média de 40% de acurácia. A baixa acurácia pode ter ocorrido pois, durante a tradução, houve perda de informação valiosa. Além disso, uma notícia em português do brasil traz consigo um contexto político e social que pode ser perdido e não fazer muito sentido ao ser traduzido para o inglês.

Além de ter um resultado não muito promissor, um forte impedimento no uso do iFeel foi a tradução para o inglês. Todas as boas API's encontradas cobram por caractere traduzido. Devido a este impedimento, optou-se por procurar um método de análise de sentimento em português.

Optou-se por utilizar o SentiStrength. O SentiStrength é um dos métodos do iFeel, e está disponível em português. Os resultados sobre o conjunto etiquetado na língua original foram superiores aos resultados sobre o conjunto após a tradução. Obteve-se uma acurácia de 67%.

6. RESULTADOS

Execução do SentiStrength

Executou-se o SentiStrength em cada manchete com o formato de output escalar. O formato escalar retorna um valor de -4 a 4 que representa o sentimento da notícia em relação a sua polaridade (-4: negativo, 4: positivo).

Após a execução do SentiStrength, selecionou-se aleatoriamente exemplos de notícias para cada um dos 7 scores. Na figura 3 percebe-se que o método é consistente. O SentiStrength utiliza um dicionário de palavras com scores pré-definidos. As frases mais negativas possuem palavras como "decapitar", "acidente" e "mortos", que acredita-se possuírem um fator negativo forte, contribuindo para o valor resultante. Já as frases mais positivas possuem palavras como "delicioso", "criançada", "orgulho" e "prazer", além de ter palavras como "muito", que são palavras que aumentam o score geral da frase.

Sentimento	Manchete
-4	Júri absolve policiais 'Highlanders' acusados de decapitar deficiente em SP
-3	Acidente com ônibus deixa ao menos 15 mortos em estrada de Paraty (RJ)
-2	Lobista preso na Lava Jato nega propina e diz não conhecer Cunha
-1	ONU denuncia tchecos por prisão sistemática de migrantes e refugiados
0	Comissão bilateral Cuba-EUA se reúne em Havana
1	Ex-camelô vira empresário de sucesso e fatura R\$ 12 mil com palestras
2	Escola realiza 'aulão' de redação do Enem de graça, em Porto Velho
3	Aprenda a fazer um delicioso pirulito de brigadeiro para a criançada
4	SP recebe sírios 'com muito orgulho e muito prazer', diz Haddad

Figura 3: Exemplos de manchetes avaliadas pelo SentiStrength

Notou-se também que dentre as 59510 notícias avaliadas, apenas 6% delas foram positivas (Figura 4), a maioria (52%) é positiva e 42% é negativa. Com esta informação, acredita-se que seja possível definir que os

jornais brasileiros de maior circulação noticiam mais notícias negativas que notícias positivas.




Figura 4: Quantidade relativa de notícias Positivas, Neutras e Negativas

Análises dos resultados

Após a execução do SentiStrength, analisou-se a quantidade de notícias positivas, negativas ou neutras por cada jornal. Na figura 5 nota-se que a quantidade de notícias positivas é mínima. O jornal que mais reportou notícias positivas no período analisado foi UOL, e o jornal que mais reportou notícias Negativas foi o G1. O Jornal que mais reportou notícias neutras foi o jornal A Tarde, da Bahia.




Figura 5: Notícias analisadas por Jornal

Analisando-se a quantidade de notícias por cada um dos 7 scores (-4 a 4), percebe-se que a maioria das notícias foi etiquetada como 0 (neutro). Logo em seguida, a segunda maior parte das notícias foi etiquetada como -1, provando que apesar da maioria ser neutro, a quantidade de notícias negativas é extremamente maior que a quantidade de notícias positivas. Além disso percebe-se que é extremamente raro encontrar notícias com valores extremos (-4 e 4), embora haja mais notícias com valores extremos negativos que positivos (figura 6 e figura 7).




Figura 6: Notícias por Score (agregado)




Figura 7: Notícias por Score (por jornal)

A figura 8 mostra com detalhes a quantidade de notícias por score no dataset completo. Há tão poucas notícias -4 e +4 que a porcentagem é praticamente nula.




Figura 8: Quantidade por Score (agregado)

Sentimento ao longo do tempo

O sentimento das notícias ao longo do tempo foi analisado. A figura 9 mostra a média de sentimento nos 7 dias da semana, no período analisado. Nota-se que a média do sentimento tende a ser menos negativa na segunda-feira (embora nunca seja um valor positivo) e vai se tornando mais negativa no decorrer da semana, até atingir seu valor mínimo na sexta-feira.




Figura 9: Média por dia da semana

A média do sentimento ao longo do tempo não mostrou-se em nenhum momento acima de 0, indicando que no geral, o sentimento reportado no período estudado foi negativo. (Figura 10).




Figura 10: Média de Score ao longo do tempo (agregado)

Entidades foram extraídas de todas as notícias analisadas, e fez-se uma nuvem de palavras para mostrar as entidades mais comentadas no período analisado. Na figura 11 observam-se estas entidades. O tamanho das palavras indica a quantidade de vezes que ela apareceu; palavras maiores foram as mais reportadas nas notícias.

Pode-se observar, na figura 10, um pico de positividade no dia 22 de Novembro de 2015, e um vale entre os dias 13 e 16 de Novembro de 2015. Para esses dois momentos, extraiu-se as entidades das notícias reportadas e fez-se duas nuvens de palavras. Uma para o extremo positivo (22 de Novembro) e outra para o extremo negativo (13 a 16 de Novembro).

Na extração de entidades do extremo negativo, observou-se a presença de palavras como "Paris", "atentados", "ataques". Acredita-se que o extremo negativo tenha ocorrido devido aos atentados terroristas acontecidos em Paris no dia 13 de Novembro de 2015. (Figura 12)

Já no extremo positivo, o aumento da positividade no sentimento das notícias ocorreu devido ao acúmulo da Mega-Sena. Muitas notícias marcadas como extremamente positivas reportavam o acúmulo da loteria. (Figura 13).




Figura 11: Entidades (geral)



Figura 12: Entidades (13-16 Novembro)




Figura 13: Entidades (22 Novembro)

As análises de sentimento ao longo do tempo permitiram concluir que o método SentiStrength aplicado a manchetes de notícias na língua portuguesa teve resultados concisos.

Além das análises sobre as notícias agregadas, analisou-se também a polaridade das notícias de cada jornal em relação à polaridade agregada dos 8 jornais ao longo do tempo. Os únicos jornais que tiveram um momento em que a média de score ultrapassou 0 foram os jornais O Tempo e A Tarde. Ambos tiveram um pico de média de score positiva no dia do acúmulo da mega-sena (22 de Novembro). Observou-se também que o

jornal Yahoo teve média extremamente negativa na mesma época. (Figura 14)




Figura 14: Jornais ao longo do tempo

7. CONCLUSÃO E TRABALHOS FUTUROS

A execução do método SentiStrength proveu bons resultados. A partir dos resultados obtidos, conclui-se que os jornais brasileiros dão mais notícias negativas do que positivas, embora reportem mais notícias neutras em sua maioria.

Acredita-se que uma boa alternativa para aumentar a acurácia do SentiStrength para análise de sentimentos sobre notícias brasileiras seria o uso da ferramenta de *Treinamento*, disponível no SentiStrength. [19] A ferramenta de treinamento recebe como entrada um dataset etiquetado e aprende valores de scores para palavras novas, e atualiza as já existentes no dicionário utilizado. Acredita-se que seja possível aumentar a acurácia pois o tipo de texto de uma manchete é diferente do texto contido em Tweets e redes sociais. O dicionário de termos do SentiStrength é primariamente baseado em tweets. Portanto, se com o dicionário existente obteve-se uma acurácia de 67%, com um dicionário aprendido após o recurso de treinamento sobre um dataset contendo manchetes de notícias a acurácia possa ser melhor para analisar outras notícias. Porém, o recurso de treinamento exige que uma quantidade grande de manchetes seja etiquetada, e essa tarefa demanda tempo.

Para trabalhos futuros, além de utilizar o recurso de treinamento do SentiStrength, pretende-se construir um ranking de entidades baseada na polaridade das notícias em que elas aparecem. Acredita-se que uma ferramenta assim seja útil em épocas de eleições, em que candidatos sejam identificados como entidades, e dessa forma haja uma consulta ao ranking para saber se o candidato está relacionado à notícias positivas ou negativas.

8. REFERÊNCIAS

- [1] Evans, H. 1974. *News headlines*, volume 3. Holt, Rinehart and Winston.
- [2] Headline Sentiment Project. Luiz N, Corey S, Kelmer, Corey W. Final project on a Devbootcamp Chicago. Available on:
https://github.com/kelmerp/headline_sentiment_rating, <http://headlines-and-data.herokuapp.com>
- [3] Breaking the News: First Impressions Matter on Online News. Julio Reis, Fabrício Benevenuto, Pedro Vaz de Melo, Raquel Prates, Haewoon Kwak and Jisun An. In *Proceedings of the Int'l AAAI Conference on Weblogs and Social Media (ICWSM'15)*. Oxford, UK, May, 2015.
- [4] Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. *Foundations and Trends in Information Retrieval*, 1(1-2), 1-135.
- [5] Balahur, A., Steinberger, R., Kabadjov, M., Zavarella, V., Goot, E. v. d., Halkia, M., et al. (2010). Sentiment analysis in the news. *Proceedings of the Seventh conference on International Language Resources and Evaluation*
- [6] Thelwall M., Buckley K, Paltoglou G., Cai D.. *Sentimento Strength Detection in Short Informal Text*. 2010.
- [7] Abbasi, A., Chen, H., & Salem, A. (2008). Sentiment analysis in multiple languages: Feature selection for opinion classification in web forums. *ACM Transactions on Information Systems*, 26(3), 12:11-12:34.
- [8] Abbasi, A., Chen, H., Thoms, S., & Fu, T. (2008). Affect analysis of Web forums and Blogs using correlation ensembles. *IEEE Transactions on Knowledge and Data Engineering*, 20(9), 1168-1180.
- [9] Stone, P. J., Dunphy, D. C., Smith, M. S., & Ogilvie, D. M. (1966). *The general inquirer: A computer approach to content analysis*. Cambridge, MA: The MIT Press.
- [10] Strapparava, C., & Valitutti, A. (2004). Wordnet-affect: an affective extension of wordnet. In *Proceedings of the 4th International Conference on Language Resources and Evaluation* (pp. 1083-1086). Lisbon.
- [11] Baccianella, S., Esuli, A., & Sebastiani, F. (2010). SentiWordNet 3.0: An enhanced lexical resource for sentiment analysis and opinion mining. *Proceedings of the Seventh conference on International Language Resources and Evaluation*

- [12] Agerri, R., & García-Serrano, A. (2010). Q-WordNet: Extracting polarity from WordNet senses. *Proceedings of the Seventh conference on International Language Resources and Evaluation*
- [13] Choi, Y., & Cardie, C. (2008). Learning with compositional semantics as structural inference for subsentential sentiment analysis. *Proceedings of the Conference on Empirical Methods in Natural Language Processing*, 793-801.
- [14] Snyder, B., & Barzilay, R. (2007). Multiple aspect ranking using the good grief algorithm. *Proceedings of NAACL HLT*.
- [15] Alchemy API. <http://www.alchemyapi.com/>
- [16] Internet Archive WaybackMachine. <http://archive.org/web/>
- [17] iFeel: A System that Compares and Combines Sentiment Analysis Methods.(WWW'14). Seoul, Korea. April 2014.
- [18] *Notícia ruim corre depressa!: Bad news travels fast!* Rocha, Luis E C Umeå University, Faculty of Science and Technology, Department of Physics. (Theoretical Physics)
- [19] SentiStrength. <http://sentistrength.wlv.ac.uk/>
- [20] ANJ - Associação Nacional de Jornais. <http://www.anj.org.br/>
- [21] Microsoft Translator API. <https://www.microsoft.com/en-us/translator/translatorapi.aspx>